

Tarea 2 IPD440 - Evaluación de Robustez y Degradación Fonética de la Arquitectura BC-ResNet-1 bajo Ruido Aditivo

1st Eduardo Mendoza Tapia
Departamento de Electrónica
Universidad Técnica Federico Santa María
Santiago, Chile
eduardo.tapiam@usm.cl

Abstract—La arquitectura BC-ResNet para el reconocimiento de palabras clave (KWS) fue evaluada en condiciones acústicas ideales, asumiendo una robustez no verificada ante interferencias del entorno real. Esta tarea investiga el impacto del enmascaramiento espectral sobre el modelo BC-ResNet-1, evaluando su desempeño bajo ruido blanco aditivo a diferentes relaciones señal a ruido (SNR $\in \{\text{Limpio}, 20, 10, 5, 0\}$ [dB]) sobre el conjunto oficial de prueba de Google Speech Commands v2. Los resultados muestran que el modelo retiene un 85,00% de exactitud global a 0 [dB] (caída de 11 puntos porcentuales respecto al 96,00% base), pero exhibe una degradación asimétrica: los comandos fonéticamente similares sufren pérdidas relativas de F1 del 19,8% y 17,1% (duplicando la media macro de 11,7%) y sextuplican su confusión mutua (hasta 6,43%), mientras que pares ortogonales (*stop*–*yes*) retienen una confusión más baja (0,36%). Este hallazgo apunta tentativamente a que el *frequency average pooling* del bloque residual colapsa la discriminabilidad de los formantes consonánticos débiles en presencia de ruido difuso. El código utilizado para esta tarea puede encontrarse en el siguiente [repositorio de GitHub](#). El notebook en línea en que se ejecutó puede encontrarse [aquí](#)

I. RESEARCH QUESTION

En el artículo de Kim et al. (2021)[1], la arquitectura BC-ResNet-1 ($\tau = 1$, 9.510 parámetros) demostró un rendimiento considerable de Keyword Spotting (KWS), alcanzando una exactitud superior al 96% sobre el dataset Google Speech Commands v2[2]. Sin embargo, la evaluación del artículo presenta una limitación: los experimentos se restringieron a condiciones de laboratorio con señales de audio limpias, asumiendo que la red preserva su capacidad de discriminación en entornos acústicos reales no controlados.

En aplicaciones reales de procesamiento de voz, los dispositivos operan sujetos a perturbaciones acústicas. La arquitectura BC-ResNet-1 utiliza bloques residuales que aplican una reducción drástica mediante Frequency Average Pooling, colapsando las 40 bandas de frecuencia Mel en un vector temporal unidimensional. Esto plantea una interrogante que el paper omite: ¿es BC-ResNet-1 robusta ante la inyección de ruido, o sufre una degradación que compromete el reconocimiento de comandos específicos?

Para dar respuesta a este vacío de evaluación, se formula la siguiente pregunta de investigación:

¿Cómo afecta la degradación de la relación señal a ruido (SNR) al desempeño de clasificación de palabras clave del modelo BC-ResNet-1 sobre Google Speech Commands v2, en términos de exactitud global (Top-1 Accuracy) y de macro F1-score?

II. HIPÓTESIS

Como respuesta tentativa a la pregunta de investigación formulada, se plantea la siguiente hipótesis experimental:

Al degradar la relación señal a ruido por debajo de 10 dB, el desempeño global de BC-ResNet-1 experimentará una caída de exactitud superior al 15% respecto al baseline, exhibiendo una degradación asimétrica donde el F1-score de pares fonéticamente similares (como 'no'-'go', 'up'-'off' y 'down'-'on') en comparación con pares acústicamente ortogonales (como 'stop'-'yes') sufrirá una caída relativa mayor, debido a que el frequency average pooling del bloque residual colapsa la discriminabilidad de los formantes consonánticos en presencia de ruido aditivo.

Esta hipótesis se fundamenta en la arquitectura del modelo y en la física de la señal de voz. El bloque BC-ResBlock de BC-ResNet-1 aplica un Frequency Average Pooling que promedia la energía de las 40 bandas Mel para colapsar la matriz bidimensional a un vector temporal 1D. En condiciones limpias, las consonantes transitorias de baja energía (como la nasal alveolar /n/, la oclusiva velar /g/ o las labiales /p/ y /f/) conservan suficiente contraste espectral para que la red discrimine palabras con rimas similares; no obstante, al inyectar ruido blanco por debajo de los 10 dB —umbral donde la potencia acústica de interferencia comienza a enmascarar los formantes más tenues—, el suelo de ruido inunda todas las frecuencias. Al promediar verticalmente en frecuencia, los transitorios consonánticos débiles se disuelven en el piso de ruido, mientras que los armónicos vocálicos de mayor energía (como el diptongo /o/ compartido por no y go) sobreviven al enmascaramiento. Como consecuencia, las representaciones intermedias colapsan hacia el núcleo vocálico común, provocando una degradación asimétrica y una confusión fonética selectiva entre comandos similares, en contraste con pares

acústicamente ortogonales (como stop y yes) que retienen su separabilidad gracias a envolventes diferenciables.

III. SETUP EXPERIMENTAL

El diseño experimental de esta investigación se fundamenta en evaluar la resiliencia acústica del modelo ante el enmascaramiento espectral (ruido añadido a la señal de voz). Para este propósito, se utilizó la partición oficial de prueba (test set) del dataset de referencia Google Speech Commands v2 (v0.02), conformada por 11.005 archivos de un segundo de duración muestreados a 16 [kHz]. El dataset se estructura bajo 12 clases, compuesto por 10 comandos (yes, no, up, down, left, right, on, off, stop, go), una clase de silencio ambiental (silence) y una clase distractor (unknown) que agrupa 25 palabras fuera de vocabulario. Como condición de control (baseline), se emplea la arquitectura BC-ResNet-1 ($\tau = 1$, 9.510 parámetros), la cual alcanza un desempeño de referencia sobre audio limpio de 96.00% de Top-1 Accuracy y un Macro F1 de 0.958. Cada audio se transforma en un espectrograma Log-Mel de 40 bandas frecuenciales y 101 pasos temporales (40×101) mediante una Transformada de Fourier de Tiempo Corto (STFT) antes de la inferencia del modelo.

La perturbación acústica se inyecta sobre la forma de onda continua unidimensional en el dominio temporal antes del extractor espectral. Para modelar el deterioro acústico sin introducir artefactos de distorsión no lineal o saturación numérica (clipping) en el intervalo normalizado $[-1.0, 1.0]$, se escala ruido blanco gaussiano aditivo ($e[n] \sim \mathcal{N}(0, 1)$) mediante el factor analítico $\alpha = \sqrt{P_{\text{señal}} / (10^{SNR/10} \cdot P_{\text{ruido}} + \epsilon)}$, calibrado de forma independiente según la potencia cuadrática media (RMS) de cada muestra de audio. La relación señal a ruido (SNR) es el factor manipulado a lo largo del estudio. Esta variable se evalúa en cinco condiciones de potencia: audio limpio de control ($SNR \rightarrow +\infty$ [dB]), ruido leve (20 [dB]), ruido moderado (10 [dB]), ruido severo (5 [dB]) y ruido crítico (0 [dB], donde la potencia del ruido iguala a la de la voz). Todos los demás elementos —incluyendo la arquitectura, los pesos, la extracción Log-Mel y la semilla pseudoaleatoria fija (SEED = 42)— permanecen invariantes a lo largo de toda la experimentación.

Entorno de ejecución

El experimento se llevó a cabo en una instancia virtual de Google Colab. Las especificaciones técnicas del entorno de cómputo fueron:

- GPU: NVIDIA Tesla T4 con 16 GB de memoria GDDR6 VRAM asignada bajo el controlador CUDA 12.8.
- CPU: 2 núcleos virtuales (vCPUs) Intel Xeon @ 2.20 GHz con arquitectura x86_64.
- Memoria: 12.7 GB de memoria RAM
- Software: Ubuntu 22.04 LTS, Python 3.13, PyTorch 2.11 (compilación con soporte CUDA), torchaudio 2.11, librosa 0.11 y soundfile 0.14

IV. PLAN DE EXPERIMENTOS

El plan experimental se estructura en dos fases para someter a prueba la hipótesis de degradación acústica y asimetría fonética. En primer lugar, se ejecutó el experimento de inferencia (baseline de control), el cual consiste en la prueba de rendimiento en BC-ResNet-1 sobre el dataset en su estado original no perturbado ($SNR \rightarrow +\infty$ dB). Esta corrida inicial permite establecer la cota superior del sistema (96.00% de Top-1 Accuracy y 0.958 de Macro F1), fijando el punto de referencia respecto al cual se midieron todas las demás inferencias con SNR alterado. En segundo lugar, se implementó la variación, consistente en un barrido de degradación donde se inyecta ruido blanco en el dominio temporal a cuatro niveles de relación señal a ruido: 20 dB, 10 dB, 5 dB y 0 dB..

A partir de estas corridas, el análisis se articula en torno a tres comparaciones y contrastes relevantes orientados a validar o refutar la hipótesis:

Contraste de Desempeño Global: Se examina la pendiente de decaimiento conjunto de la Top-1 Accuracy y el Macro F1 a través de las cinco condiciones, evaluando si la pérdida de exactitud supera los 15 puntos porcentuales por debajo de los 10 dB para contrastar el criterio de falsabilidad.

Contraste Inter-Clase de Asimetría ($\Delta F1_{\text{rel}}$): Se compara la pérdida relativa porcentual de cada una de las 12 clases individuales frente a la línea media del sistema, con el fin de verificar si el ruido degrada el vocabulario de forma homogénea o si penaliza a comandos específicos.

Contraste de Confusión Fonética Cruzada: Se evalúa la evolución de la tasa de confusión mutua entre pares fonéticamente vulnerables (no $\leftrightarrow$ go, up $\leftrightarrow$ off, down $\leftrightarrow$ on y yes $\leftrightarrow$ left) en comparación directa con un par de control acústicamente ortogonal (stop $\leftrightarrow$ yes); para discriminar si los fallos del modelo responden a una dispersión aleatoria por ruido ciego o si confirman el mecanismo causal de colapso de formantes consonánticos en el frequency average pooling.

V. EXPERIMENTOS INICIALES (IMPLEMENTACIÓN Y PIPELINE)

se implementó un pipeline de inferencia y perturbación acústica de extremo a extremo en con PyTorch. La ejecución de esta primera fase permitió validar 2 aristas del sistema antes de las inferencias y análisis de métricas: la estabilidad del modelo preentrenado (baseline) y la calibración del algoritmo de inyección de ruido.

En primer lugar se verificó la correcta carga del modelo (best_model.pt), siendo BC-ResNet-1 ($\tau = 1$, 9.510 parámetros). Esta corrida funcional sobre el cargador de pruebas oficial (test_loader, compuesto por 11.005 archivos monoaurales a 16 kHz) reprodujo el desempeño esperado (96.00% de Top-1 Accuracy y 0.958 de Macro F1), confirmando la ausencia de discrepancias de resultados respecto a su exactitud planteada. Asimismo, se aseguró la reproducibilidad del proceso fijando la semilla pseudoaleatoria del sistema (SEED = 42 en Python, NumPy y PyTorch CUDA), lo que asegura que las secuencias de ruido generadas y el ordenamiento de los lotes de datos permanezcan idénticos.

En segundo lugar, se sometió el mecanismo de perturbación a un protocolo de verificación numerica y representacional para asegurar que la degradación acústica modelara un enmascaramiento sin inducir saturación o distorsión (clipping). La inyección temporal de ruido blanco gaussiano ($e[n] \sim \mathcal{N}(0, 1)$) escalado mediante la potencia cuadrática media (RMS) de cada muestra se verificó calculando la relación señal a ruido real (SNR_{medido}). Mientras que la condición base limpia arrojó un error nulo ($SNR \rightarrow +\infty$ dB), las condiciones perturbadas registraron 20.00 [dB], 10.00 [dB], 5.00 [dB] y 0.00 [dB]. La inspección de las formas de onda unidimensionales y de los espectrogramas Log-Mel bidimensionales (40×101) confirmó visualmente que las amplitudes oscilatorias se mantuvieron dentro del rango permitido $[-1.0, 1.0]$ y que la energía difusa saturó progresivamente el plano tiempo-frecuencia hasta ocultar los formantes vocálicos débiles a 0 dB.




Fig. 1. Verificación de ruido aditivo para el comando 'NO'.

VI. RESULTADOS

La evaluación del modelo permitió caracterizar el impacto de la degradación por relación señal a ruido (SNR). A continuación, se desglosan los hallazgos:

A. Trayectoria de Degradación Global




Fig. 2. Curva de degradación frente a ruido aditivo.

En la condición de control, el clasificador fijó una cota superior de 96.00% de Top-1 Accuracy y un Macro F1 de 0.958. Al inyectar ruido leve a 20 [dB], el modelo exhibió una degradación de 1.00 punto porcentual (95.00% de exactitud y 0.948 de Macro F1), comportamiento esperable, dado que la energía de la voz domina holgadamente sobre el suelo de ruido. Sin embargo, tal como se aprecia en la Figura 2, la trayectoria del sistema sufre un cambio de pendiente al cruzar la línea vertical punteada que demarca el umbral de los 10 [dB]. A partir de este nivel, la curva desciende de forma acelerada hacia un 93.20% a 10 [dB], 90.70% a 5 [dB] y alcanza un valor final de 85.00% en la condición de 0 [dB] (con un Macro F1 de 0.846).

B. Vulnerabilidad Asimétrica del Vocabulario por Clase




Fig. 3. Curva de degradación frente a ruido aditivo.

Para cuantificar la disparidad en el deterioro de cada comando frente al promedio global, se calculó la tasa de pérdida relativa porcentual de F1-score al pasar de audio limpio a ruido crítico ($\Delta F1_{rel} = [(F1_{Limpio} - F1_{0\text{ dB}}) / F1_{Limpio}] \times 100$). Como ilustra la Figura 3, las 12 categorías del dataset se ordenaron de manera descendente y se contrastaron frente a la línea discontinua que señala la caída promedio macro del sistema (11.7%).

C. Matrices de confusión




Fig. 4. Matrices de confusión Baseline y SNR = 0 [dB].

La inspección comparativa de las matrices de confusión por fila (recall por clase) expone hacia dónde migran las predicciones cuando el clasificador se ve privado de certidumbre

TABLE I
RENDIMIENTO GLOBAL DE BC-RESNET-1 ANTE DEGRADACIÓN ACÚSTICA POR RELACIÓN SEÑAL A RUIDO (SNR).

Condición Acústica (SNR)	Top-1 Accuracy (%)	Δ Acc. (pp)	Macro F1-Score	Δ F1 Rel. (%)
Limpio (Baseline)	96.00	—	0.9580	—
Ruido 20 dB	95.00	-1.00	0.9480	-1.04
Ruido 10 dB	93.20	-2.80	0.9300	-2.92
Ruido 5 dB	90.70	-5.30	0.9050	-5.53
Ruido 0 dB	85.00	-11.00	0.8460	-11.69

espectral. En la Figura 4, el en Baseline el modelo opera con un régimen ideal, concentrando la totalidad de su densidad en la diagonal principal con sensibilidades que superan el 95% en casi todas las clases y una dispersión fuera de la diagonal despreciable.

Para la matriz de SNR = 0 [dB] se observa una atenuación de los valores diagonales. Cuando la interferencia destruye la estructura de los formantes, la red pierde confianza en los comandos objetivo y opta por clasificar la entrada como sonido desconocido o silencio. También, emergen puntos de confusión mutua entre comandos específicos fuera de la diagonal principal. Se aprecian transferencias simétricas notables entre la fila de "no" y la columna de "go" (y viceversa), así como entre "off" y "up".

D. tasa de confusión de pares




Fig. 5. Confusión en pares cercanos fonéticamente para distintos SNR.

Se midió la trayectoria de la tasa de confusión mutua porcentual ($\text{Confusión Mutua}_{A \leftrightarrow B} = [(C_{A \rightarrow B} + C_{B \rightarrow A}) / (N_A + N_B)] \times 100$) para cuatro pares de palabras fonéticamente cercanas, contrastándolos frente a un par de control acústicamente ortogonal (stop $\leftrightarrow$ yes).

VII. ANÁLISIS

Al contrastar los resultados con la hipótesis formulada, se observa una discrepancia en la resiliencia global del sistema. La hipótesis postulaba una caída de exactitud superior a 15 puntos porcentuales respecto al baseline limpio (96.00%) al operar por debajo de los 10 dB. No obstante, los datos recolectados refutan parcialmente esta predicción: en la condición crítica de 0 [dB], el clasificador retuvo un

85.00% de Top-1 Accuracy. Esto representa un descenso de 11 puntos porcentuales (11.46% de pérdida relativa). Este resultado evidencia que la arquitectura BC-ResNet-1 posee una robustez global ante ruido aditivo superior a la anticipada. Las conexiones residuales transmitidas (Broadcasted Residual Learning) y la normalización subespectral (SSN) logran preservar una separabilidad notable incluso cuando la potencia de interferencia iguala a la señal de voz.

En contraste con la resistencia global, la segunda dimensión de la hipótesis —la existencia de una degradación asimétrica concentrada en comandos homófonos— se confirmó. Mientras que el promedio macro del sistema experimentó un deterioro relativo de F1 de 11.7%, los comandos fonéticamente homófonos "no" y "go" sufrieron caídas relativas del 19.8% y 17.1% respectivamente. Como evidencia la Figura 2, ambas clases casi duplicaron la tasa de degradación media del modelo, situándose en los primeros lugares de vulnerabilidad del corpus y siendo superadas únicamente por la categoría distractora unknown (20.1%). Por el contrario, comandos caracterizados por consonantes de alta energía o fricativas sibilantes como "on" (6.4%), "right" (7.8%) y "yes" (8.2%) demostraron una elevada inmunidad acústica, confirmando que el impacto del enmascaramiento no se distribuye homogéneamente sobre el vocabulario.

La trayectoria de confusión cruzada mutua de la Figura 4 muestra que los fallos del modelo no corresponden a ruido aleatorio, sino a una confusión por similitud fonética. La tasa de confusión mutua entre "no" y "go" se sextuplicó al pasar de 1.13% en condición limpia a 6.43% a 0 dB. De forma análoga, el par "up $\leftrightarrow$ off" (cuyos fonemas de cierre corresponden a labiales tenues /p/ y /f/) escaló su confusión mutua hasta un 7.50%. Como contraprueba experimental, el par de control acústicamente ortogonal (stop $\leftrightarrow$ yes) retuvo una confusión mutua prácticamente nula en todo el barrido, registrando apenas un 0.36% a 0 [dB]. Este comportamiento muestra que cuando las trayectorias de formantes y las envolventes temporales son marcadamente disímiles, la red preserva la separabilidad de las clases con total independencia del piso de ruido.

El mecanismo que explica este colapso selectivo radica en la compresión frecuencial del bloque BC-ResBlock. Para mantener un costo de 9.510 parámetros, la arquitectura promedia globalmente las 40 bandas Mel ($H = 40 \rightarrow 1$). En audio limpio, los transitorios consonánticos débiles (el flujo nasal de /n/ o la oclusión velar de /g/) conservan suficiente

contraste espectral relativo. Sin embargo, el ruido blanco inyecta una densidad de potencia homogénea en todo el espectro. Al aplicar el promediado frecuencial, los formantes consonánticos de baja energía se disuelven en el piso de ruido aditivo. Dado que "no" y "go" comparten el núcleo vocálico /o/ (cuyos armónicos de alta energía sobreviven al enmascaramiento), el vector temporal 1D colapsa hacia una representación prácticamente idéntica, provocando que el modelo tiendo a confundir ambos comandos.

VIII. AJUSTES PROPUESTOS

A partir del colapso asimétrico observado en los comandos homófonos y de la resiliencia global de BC-ResNet-1, se propone modificación. La primera intervención consiste en incorporar un esquema de entrenamiento consciente de ruido. Dado que el modelo base fue optimizado sobre señales limpias, se podría aplicar un aumento de datos inyectando perturbaciones aditivas en el 50% de los lotes de entrenamiento con niveles de SNR muestreados aleatoriamente entre 0 dB y 20 dB. Esta regularización acústica forzaría a los filtros convolucionales a extraer características de mayor invariancia espectral, mitigando la dependencia de crestas de energía limpia.

Riesgos

El principal riesgo radica en la pérdida de precisión y exactitud del modelo provocada por el compromiso (trade-off) entre robustez acústica y desempeño en condiciones ideales. Al implementar el entrenamiento consciente de ruido para mitigar el enmascaramiento de formantes, la regularización excesiva puede desensibilizar los filtros convolucionales ante señales de alta fidelidad, degradando la exactitud de control del 96% sobre audios limpios.

REFERENCES

- [1] B. Kim, S. Chang, J. Lee, and D. Sung, "Broadcasted Residual Learning for Efficient Keyword Spotting," in *Proc. Interspeech 2021*, 2021, pp. 4531–4535.
- [2] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," *arXiv preprint arXiv:1804.03209*, 2018.
- [3] Qualcomm AI Research, "BC-ResNet: Broadcasted Residual Learning for Efficient Keyword Spotting," 2021. [En línea]. Disponible en: <https://github.com/Qualcomm-AI-research/bcresnet>.